Beslutsunderlag, California Housing Machine Learning | Spår A, Regression

Elisabeth Weise

1. Mål & valt spår

Kunden vill kunna göra grova värderingar av bostadsområden i Kalifornien för att planera investeringar och resurser. Målet är att bygga en modell som förutsäger median_house_value, medianvärdet på bostäder i ett område, baserat på områdets egenskaper.

Jag valde spår A (Regression) eftersom jag tyckte att det passade för prisprognoser i dollar,snarare än klassningar. (Det var också roligt att göra en regressionsanalys efter gruppuppgiftens klassificeringsanalys.)

2.Data-insikt (EDA)

Datasetet innehåller 20 640 rader och 10 kolumner där varje rad representerar ett område i Kalifornien. Nio kolumner är numeriska och en (ocean_proximity) är kategorisk med fem unika värden. Kolumnen total_bedrooms har 207 saknade värden som hanteras med median-imputation i pipeline.

Korrelationsmatris

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value
longitude	1.00	-0.92	-0.11	0.04	0.07	0.10	0.06	-0.02	-0.05
latitude	-0.92	1.00	0.01	-0.04	-0.07	-0.11	-0.07	-0.08	-0.14
housing_median_age	-0.11	0.01	1.00	-0.36	-0.32	-0.30	-0.30	-0.12	0.11
total_rooms	0.04	-0.04	-0.36	1.00	0.93	0.86	0.92	0.20	0.13
total_bedrooms	0.07	-0.07	-0.32	0.93	1.00	0.88	0.98	-0.01	0.05
population	0.10	-0.11	-0.30	0.86	0.88	1.00	0.91	0.00	-0.02
households	0.06	-0.07	-0.30	0.92	0.98	0.91	1.00	0.01	0.07
median_income	-0.02	-0.08	-0.12	0.20	-0.01	0.00	0.01	1.00	0.69
median_house_value	-0.05	-0.14	0.11	0.13	0.05	-0.02	0.07	0.69	1.00

1. **Stark korrelation med inkomst:** Heatmappen visar att median_income har starkast korrelation med target median_house_value.

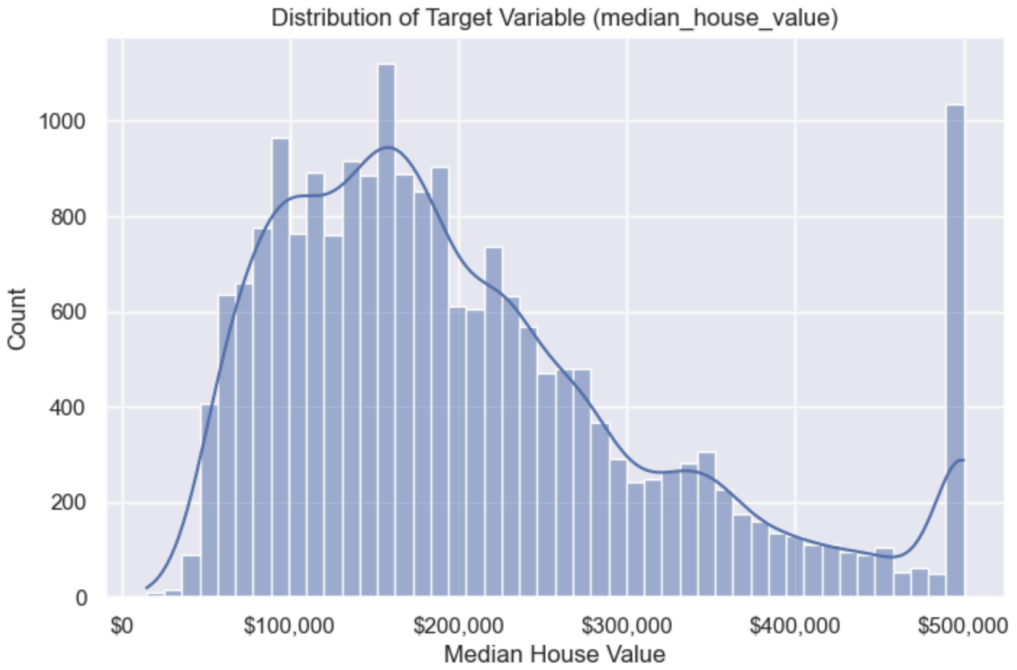

2. **Skev distribution:** Histogrammet visar att fördelningen av huspriserna är sne och att det finns tydliga outliers kring $500,000. Jag tror att datasetet cappar värden vid $500,000, så att alla hus värda mer än så ändå registreras som $500,000.
3. **Liten ISLAND-kategori:** Kategorin ISLAND i ocean_proximity förekommer i endast 5 av 20,640 rader (0.02%), vilket gör förutsägelser för ö-lägen opålitliga.

3. Metod

Testdatan används för att simulera hur modellen presterar på ny, osedd data. Den används enbart för den slutliga utvärderingen och rördes inte under modellval eller tuning.

Jag delade datan 80/20 (träning / test) med random_state=42 för reproducerbarhet. Modellerna jämfördes med 5-fold CV på träningsdatan.Tre nya features skapades för att få mer detaljer om variabler som kan påverka huspriser i ett område:
rooms_per_household,
bedrooms_per_room
population_per_household.

All preprocessing (imputation, skalning, OneHotEncoding) skedde inuti en Pipeline för att garantera att testdatan inte påverkade träningsdatan.
Fyra modeller testades: DummyRegressor (baseline), Linear Regression, Random Forest och Gradient Boosting. Modellerna rankades med hjälp av RMSE, då datan innehåller outliers och RMSE straffar stora fel hårdare än MAE.

4. Resultat

CV-jämförelse av modeller på träningsdata

Modell	CV RMSE (mean)	CV RMSE (std)	CV R2 (mean)
Baseline (median)	$88,597	$2,924	-0.056
Linear Regression	$48,880	$982	0.655
Gradient Boosting	$36,606	$556	0.791
Random Forest	$32,911	$517	0.811

Resultat efter tuning av Random Forest på träningsdata

Parameter	Testat	Bästa värde
n_estimators	100, 200, 300	300
max_depth	None, 10, 20	None
min_samples_split	2, 5	2
RMSE efter tuning		$50,112

Resultat efter tuning av Random Forest på testdata

Metric	Värde	Tolkning
MAE	$31,774	Snittfel per område
RMSE	$49,447	Straffar stora fel hårdare än MAE
R2	0.81	81% av variationen förklaras av modellen

Test-RMSE ($49,447) ligger nära CV-RMSE ($50,112), vilket visar att modellen är stabil och inte overfittar.

Modellvariabler (Topp 5)

Feature	Importance
median_income	0.481
ocean_proximity_INLAND	0.139
population_per_household	0.121
longitude	0.058
latitude	0.057

median_income (48%) är den enskilt viktigaste faktorn för hur modellen förutspår huspriser i ett område. Det kunde vi utläsa redan från rådatan men vi måste också ta i beaktande att det finns ett cirkelargument här - hushållsinkomst och huspriser mäter till stor samma sak, hur välbärgat ett område är.

Vi kan också se att geografi påverkar huspriserna i ett område, med strandnära placeringar som förklarar 14% av hur modellen förutspår huspriser. Lägger vi till longitude och latitude ser vi att georgrafiska indikatorer tillsammans bidrar med cirka 25% av hur modellen förutspår huspriser. Detta bekräftades vidare av KMeans resultatet som visade att geografi är en stark faktor i datan.

Vidare såg vi att antalet personer i hushållet (en variabel vi skapade som del av feature engineering för modellen) bidrog till 12% av hur modellen förutspår huspriser. Genom att titta på en scatterplot kunde vi konstatera att fler personer per hushåll är associerat med lägre huspriser. Trångboddhet är vanligare i mindre välbärgade områden.

5. Rekommendation

Jag rekommenderar den tunede **Random Forest-modellen** (n_estimators=300, max_depth=None, min_samples_split=2). Modellen förklarar 81% av variationen i bostadspriserna och missar i snitt med $32,000 per område, ungefär 17% av huspris medianvärdet på $180,000.

6. Risker & begränsningar

Cappade värden: Datasetet sätter tak vid $500,000 vilket gör att modellen underskattar värdet på de dyraste områdena.
Geografisk begränsning: Modellen är tränad enbart på Kalifornien och kan inte generaliseras till andra delstater eller länder utan ny träning.
Datakvalitet: Datan är per område, inte per enskilt hus. Detaljnivån är därför låg, vilket gör att även detaljnivån på prognoserna blir grova.

7. Oövervakad inlärning

Till skillnad från övervakad inlärning försöker oövervakad inlärning hitta mönster och struktur i data utan ett fördefinierat target. I det här projektet försöker vi se om det finns grupper av områden som liknar varandra vad det gäller olika variabler, vilket skulle kunna hjälpa kunden att segmentera marknaden.

PCA komprimerar data med många variabler till färre, för att visualisera mönster.
KMeans grupperar datapunkterna i K kluster baserat på likhet.
Risker/fallgropar: KMeans är känslig för skalning. Det finns heller inget klart rätt eller fel kring hur man manuellt väljer antalet K. Elbow- och silhouetteanalys ger vägledning men vi måste själva bestämma K. Jag är också medveten om att modellen alltid kommer att hitta mönster i datan och att det är upp till mig att utvärdera om de är användbara kluster eller inte.

Implementation: KMeans kördes med K=3 baserat på elbow-kurvan (silhouette-analys föreslog K=2, men jag valde ändå K=3 för mer nyanserad segmentering). För modellen inkluderade jag alla numeriska X-variabler (exklusive median_house_value som är target) samt de tre feature engineering-variablerna. ocean_proximity exkluderas eftersom KMeans kräver numeriska värden. Alla features standardiseras med StandardScaler.

Resultat: De tre klustren separeras primärt efter geografi. När man ritar ut dem på en karta blir det dock tydligt att det finns ett nordligt och ett sydligt kluster, medan det tredje klustret som modellen identifierar täcker båda regionerna. Det kan möjligtvis representera storstadsregioner. Klustren skulle kunna användas för att segmentera marknaden regionalt och på så sätt vara ett beslutsstöd för investeringar. Dock är klustren så grovt indelade (tre kluster för hela Kalifornien) att jag har svårt att se att en sådan modell skulle vara till nytta för några slags reella byggbeslut.

8. Självreflektion

Vad gick bra: Jag lyckades bygga ett komplett ML-flöde och få fram modelljämförelser som jag förstod och kunde tolka utifrån caset.
Vad var svårast: Avvägningen mellan hyperparameter tuning och hur lång tid det tar att köra modellen. Vad är “good enough” och när är det värt att fortsätta att hitta förbättringar. Och att ta ett beslut kring antalet kluster i min KMeans analys. Jag lyckades inte heller hålla rapporten inom 2 sidor!
Betygsbedömning: Jag bedömer att min inlämning motsvarar G. Jag har uppfyllt samtliga G krav och några av VG kraven.